



PROJET MACHINE LEARNING

Prédiction des Maladies Cardiovasculaires

Projet Machine Learning End-to-End pour la Détection Précoce
des MCV



Takwa Haj

Année Académique 2025–2026



2026



Santé Publique

Contexte et Enjeux



Décès Annuels

17,9M

17,9 millions de décès annuels dus aux maladies cardiovasculaires selon l'OMS (2023)

 Source: OMS, 2023



Classement Mondial

#1

Première cause de décès mondiale, devant le cancer et le diabète

 Impact global majeur



Prévention

80%

80% des cas sont évitables avec une détection précoce et des changements de mode de vie

 WHO CVD Report



Question de Recherche

Comment construire un classificateur ML fiable capable de prédire les maladies cardiovasculaires à partir de données cliniques et de mode de vie ?



Données

Stratégie Multi-Sources

Fusion de trois cohortes complémentaires pour améliorer la généralisation du modèle



UCI Heart Disease

Hospitalier

 Patients 1 025

 Variables 14

 Prévalence ~46%

 Usage Diagnostic confirmé

 UCI ML Repository



Framingham Heart Study

Populationnelle

 Patients 4 240

 Variables 15

 Prévalence ~15%

 Usage Risque sur 10 ans

 NHLBI / Kaggle



Kaggle CVD Dataset

Dépistage

 Patients 70 000

 Variables 12

 Prévalence ~50%

 Usage Population générale

 Kaggle (Sulianova)



Total Patients Fusionnés

75 265

 Objectif de la Fusion

Améliorer la généralisation du modèle aux trois contextes de soins : hospitalier, épidémiologique et préventif.



Pipeline Machine Learning

1

Définition du Problème

Classification binaire : MCV Présente (1) vs Absente (0)



2

Analyse Exploratoire (EDA)

Statistiques, visualisations, détection d'anomalies



3

Prétraitement & Nettoyage

Imputation, encodage, normalisation des données



4

Ingénierie des Caractéristiques

Création de variables cliniques pertinentes



5

Entraînement des Modèles

Comparaison de 4+ algorithmes (Logistic Regression, Random Forest, etc.)



6

Évaluation & Optimisation

RandomizedSearchCV, validation croisée stratifiée



7

Conclusions & Perspectives

Analyse des erreurs cliniques et recommandations





Exploration

Analyse Exploratoire

Identification des prédicteurs clés et insights cliniques majeurs



Principaux Prédicteurs

1

thal (thalassémie)

Coefficient: **+0.53** — Anomalie sévère associée

2

ca (vaisseaux colorés)

Coefficient: **+0.47** — Sténoses coronaires

3

oldpeak (dépression ST)

Coefficient: **+0.43** — Ischémie myocardique

4

cp (type de douleur)

Coefficient: **+0.43** — Douleur asymptomatique = risque élevé

5

thalach (FC max)

Coefficient: **-0.42** — Protecteur



Déséquilibre de Classes

UCI

46% — Équilibré

Framingham

15% — Déséquilibré

Kaggle

50% — Équilibré



Insights Cliniques



Sexe masculin

Prévalence significativement plus élevée chez les hommes



Âge > 55 ans

Risque exponentiellement croissant avec l'âge



Douleur asymptomatique

Paradoxalement associée au risque maximal



FC maximale élevée

Facteur protecteur (bonne condition physique)



Données issues de l'analyse de corrélation UCI



Préparation

Prétraitement & Ingénierie



Transformations Appliquées



Imputation

UCI, Framingham Médiane



Binarisation cible

UCI target > 0 → 1



Conversion âge

Kaggle Jours → Années



Recodage sexe

Kaggle 2→M, 1→F



Filtrage BP

Kaggle 60-250 / 40-150



Filtrage IMC

Kaggle 15-55



Gestion outliers

Tous IQR + clinique



Variables Créées

1

Groupes d'âge

```
age_group = pd.cut(age, bins=[0, 40, 50, 60, 100])
```

4 catégories : <40, 40-50, 50-60, 60+

2

Indicateur d'hypertension

```
hypertension = (bp_systolic >= 140).astype(int)
```

Seuil clinique : PA systolique $\geq$ 140 mmHg

3

Niveau de sévérité tensionnelle

```
bp_severity = pd.cut(bp_systolic, bins=[0, 120, 130, 140, 180, 300])
```

5 niveaux : Normale, Élevée, HTA Stade 1-2, Crise

4

Indicateurs d'obésité

```
obese = (BMI >= 30).astype(int)  
overweight = (BMI.between(25, 30)).astype(int)
```

Classification WHO de l'IMC



Modèles et Résultats

Comparaison des algorithmes et justification des métriques cliniques

Comparaison des Algorithmes

Modèle	Type	Accuracy	F1-Score	AUC-ROC	Rappel
Régression Logistique Baseline linéaire	Linéaire	0.76	0.74	0.82	0.72
Arbre de Décision Non-linéaire simple	Arbre	0.74	0.73	0.78	0.70
Random Forest Ensemble (200 arbres)	Ensemble	0.84	0.83	0.91	0.85
Random Forest (Optimisé)	Ensemble ★	0.86	0.85	0.93	0.87
Recherche d'hyperparamètres					

⚠ Limites de l'Accuracy

- ✖ **Déséquilibre de classes** : Framingham à 15% positifs → modèle trivial "tout négatif" = 85% accuracy !
- ✖ **Coût asymétrique** : En contexte clinique, faux négatif (cas manqué) >> faux positif (fausse alarme)

✓ Métriques Pertinentes

- ⚖ **F1-Score**
Moyenne harmonique Précision/Rappel — Équilibre entre sur/sous-diagnostic
- 📈 **AUC-ROC**
Discrimination indépendante du seuil — Capacité à séparer malades/sains
- 🎯 **Rappel (Sensibilité)**
CRITIQUE : Ne pas manquer de cas — Priorité clinique absolue



Meilleur Modèle

Random Forest Optimisé



Hyperparamètres Optimaux

Trouvés via RandomizedSearchCV

n_estimators	300
max_depth	10
min_samples_split	5
min_samples_leaf	3
max_features	sqrt
class_weight	balanced



Performance Globale

AUC-ROC

0.93

Grade clinique

F1-Score

0.85

Excellent équilibre

Accuracy

0.86

Haute précision

Rappel

0.87

Sensibilité élevée



Importance des Variables

1	bp_systolic	0.18
Pression artérielle systolique		
2	age	0.16
Âge du patient		
3	cholesterol_val	0.14
Taux de cholestérol		
4	heart_rate_max	0.12
Fréquence cardiaque maximale		
5	BMI	0.10
Indice de masse corporelle		
6	hypertension	0.08
Flag HTA (≥ 140 mmHg)		



Analyse des Erreurs

Matrice de confusion et interprétation clinique des erreurs de prédiction



Matrice de Confusion

	Prédit Pas de MCV	Prédit MCV
Réel Pas de MCV	✓ ~820 Vrai Négatif	! ~95 Faux Positif
Réel MCV	✗ ~65 FAUX NÉGATIF	✓ ~680 Vrai Positif



Sur ~1 660 cas de test



Interprétation Clinique

Type d'Erreur	Nombre	Taux	Impact	Priorité
Vrais Positifs	~680	—	Détection correcte	Essentiel
Vrais Négatifs	~820	—	Exclusion correcte	Essentiel
Faux Positifs	~95	~11%	Fausse alarme	Gérable
Faux Négatifs	~65	<9%	Cas manqués	CRITIQUE



Profil des Cas Manqués



Âge moyen

Plus jeunes (~52 vs 58 ans)



PAS moyenne

Légèrement inférieure (~135 vs 142 mmHg)



Présentation

Moins de symptômes classiques



Recommandation

Priorité Absolue

Minimiser les faux négatifs — Un cas de MCV manqué a des conséquences cliniques bien plus graves qu'une fausse alarme.

Action Recommandée

Optimisation du seuil de classification pour favoriser le rappel (sensibilité).



Synthèse

Conclusions



Résultats Principaux Atteints



Performance clinique

AUC-ROC = 0.93 (grade clinique)



Généralisation

Fusion multi-sources efficace



Identification facteurs

Âge, PA, cholestérol dominants



Gestion déséquilibre

SMOTE + class_weight efficaces



Taux de faux négatifs

<9% (seuil screening)



Forces du Projet

1

Méthodologie rigoureuse

Validation croisée stratifiée, recherche d'hyperparamètres systématique

2

Données diversifiées

Trois contextes cliniques différents (hospitalier, épidémiologique, préventif)

3

Focus clinique

Optimisation pour minimiser les cas manqués (faux négatifs)

4

Reproductibilité

Code modulaire, documentation complète, pipelines structurés



Limites et Mitigations



Biais populationnel

Framingham : population caucasienne âgée

→ **Mitigation:** Validation externe nécessaire sur populations diverses



Données manquantes

Kaggle : absence de features diagnostiques avancées

→ **Mitigation:** Complémentarité avec UCI pour features diagnostiques



Seuil fixe

0.5 par défaut sans optimisation coût-asymétrique

→ **Mitigation:** Optimisation future du seuil selon contexte clinique



Explicabilité

RF moins interprétable que la régression logistique

→ **Mitigation:** SHAP values à intégrer pour explications individualisées



Améliorations

Perspectives et Travaux Futurs



Améliorations Techniques Prioritaires

Priorité	Tâche	Méthode	Impact Attendu
HAUTE	Optimisation seuil	Courbe ROC + coûts asymétriques	Réduction FN <5%
HAUTE	Explicabilité	SHAP values	Acceptation clinique
MOYENNE	Modèles avancés	TabNet, XGBoost, MLP	AUC >0.95
MOYENNE	Validation externe	Nouveau jeu hospitalier	Généralisation
BASSE	Pipeline MLOps	Docker + FastAPI	Déploiement



Déploiement Clinique Envisagé



Base de Données



Prochaines Étapes Immédiates

1

Intégration SHAP

Explications individualisées pour chaque prédiction

2

Tuning du seuil

Minimisation du coût clinique total

3

Test sur données externes

Validation sur cohorte indépendante

4

Développement API

Prototype de service web avec FastAPI



Merci de votre attention

Questions et discussion



Takwa Haj

Projet de Machine Learning



2025-2026

Année Académique



Contact

takwa.haj@polytechnicien.tn



github.com/takwa-haj/cardiovascular-ml